APRENDIZAJE AUTOMÁTICO

Práctica 2

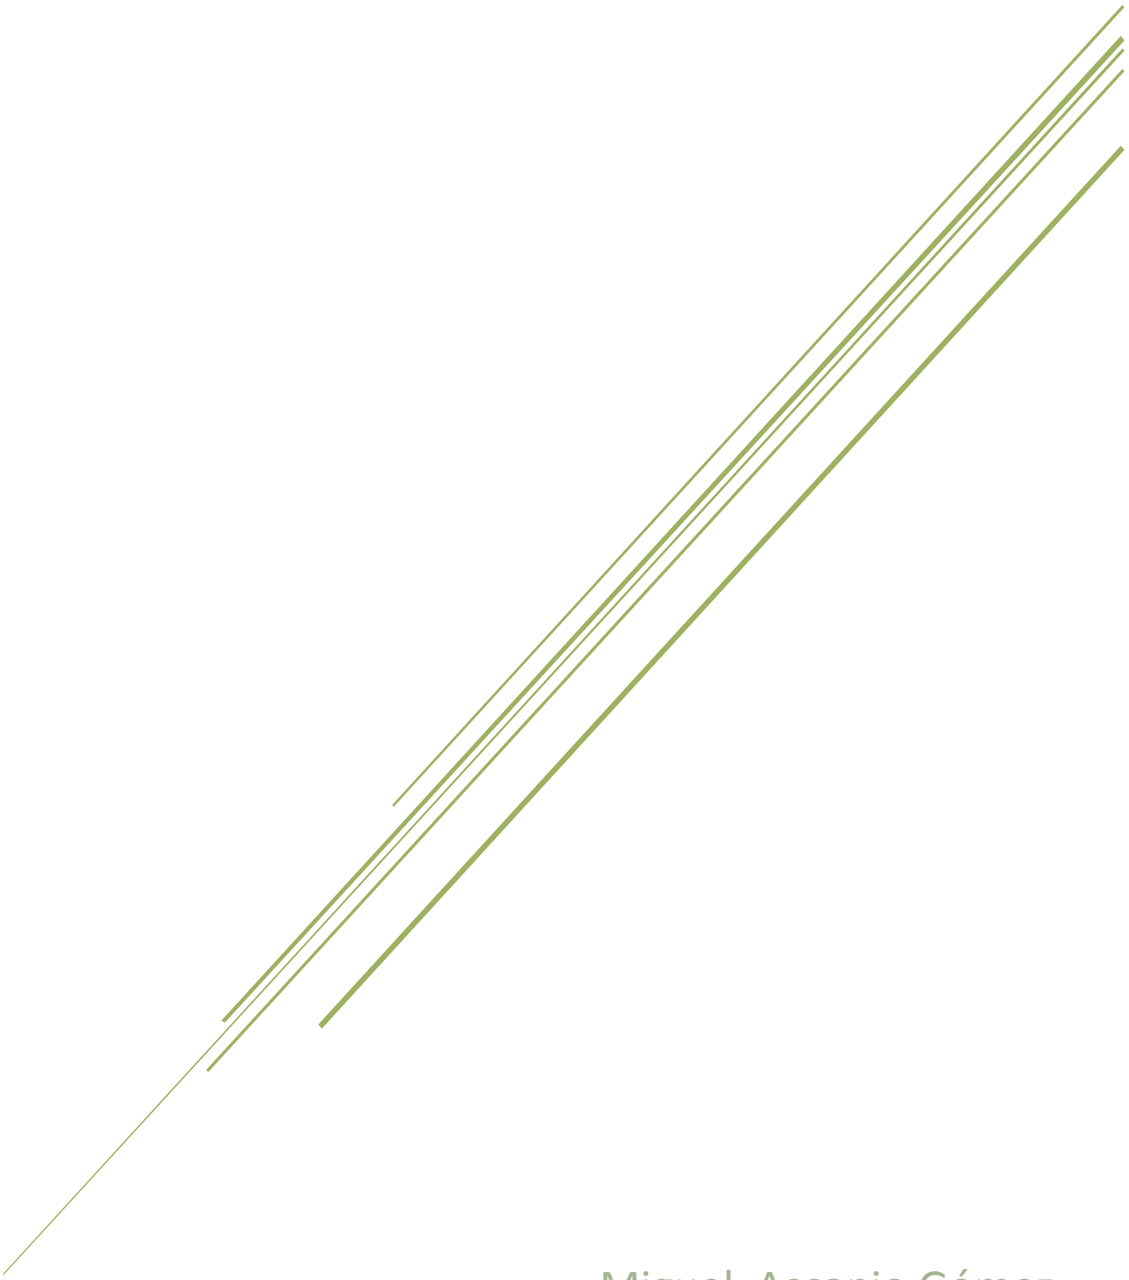

Miguel Ascanio Gómez

Esther Ávila Benito

PARTE 1

VISUALIZACIÓN DE LOS DATOS

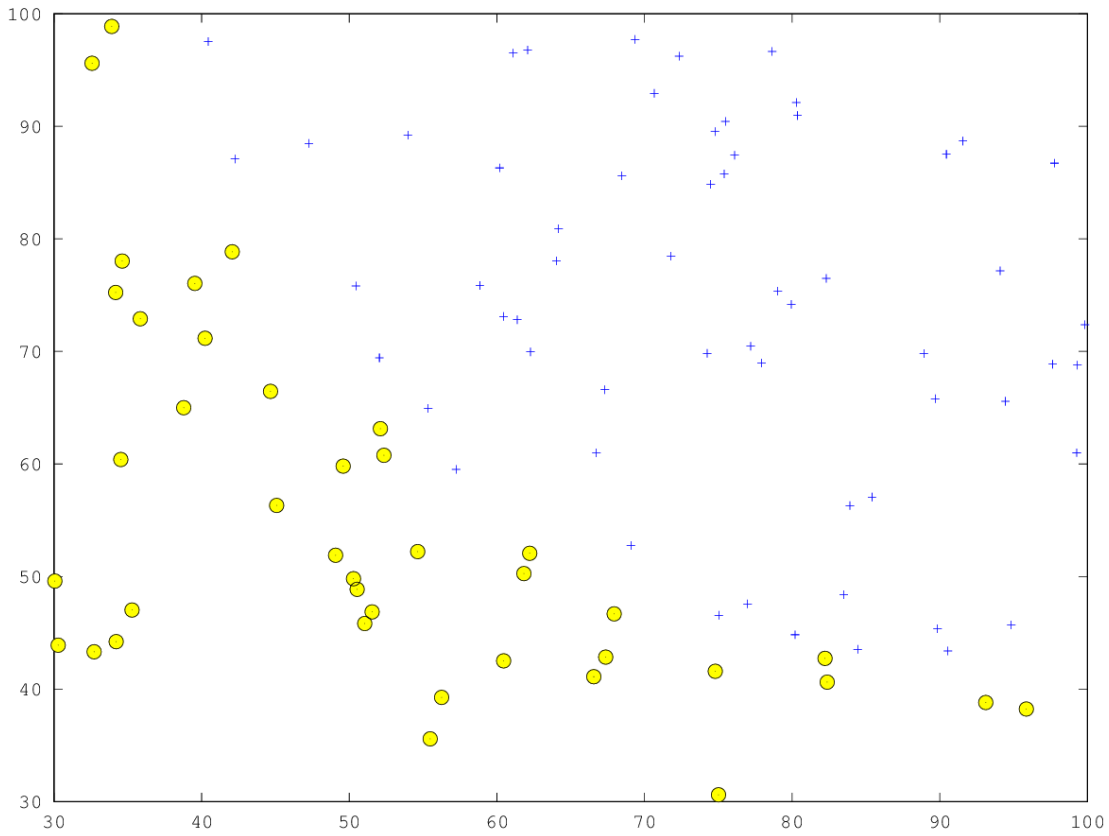

FUNCIÓN SIGMOIDE

```
function s = sigmoide(z)

	zNeg = zeros(length(z(:,1)), length(z(1,:))) .- z;

	s = 1./(1+e.^(zNeg));

endfunction
```

FUNCIÓN DE COSTE Y GRADIENTE

```
function [J, grad] = coste(theta, X, Y)
	warning("off", "Octave:broadcast");
	m = length(X(:,1));
	valoresH = (theta' * X')';
	h = sigmoide(valoresH);

	a = (0.-Y) .* log(h) .- ((1 .- Y) .* log(1 .- h));
	J = (1/m) * sum(a);
	a = (h .- Y) .* X;

	grad = 1/m * sum(a);
	warning("on", "Octave:broadcast");
endfunction
```

CÁLCULO Y REPRESENTACIÓN

```
# Lectura de datos
s = load("ex2data1.txt");
X = s(:,1:2);
y = s(:,3);
m = length(X(:,1));
X = [ones(m,1), X];
# Inicialización de theta
thetaIni = zeros(length(X(1,:)),1);
# Cálculo de coste y gradiente
[J, grad] = coste(thetaIni, X, y);
# Representación
opciones = optimset ('Gradobj', 'on', 'MaxIter', 400);
[theta, cost] = fminunc (@(t)(coste(t, X, y)), thetaIni, opciones)
plotDecisionBoundary(theta, X, y);
```

El coste obtenido es de 0.20350, y la representación es la siguiente:

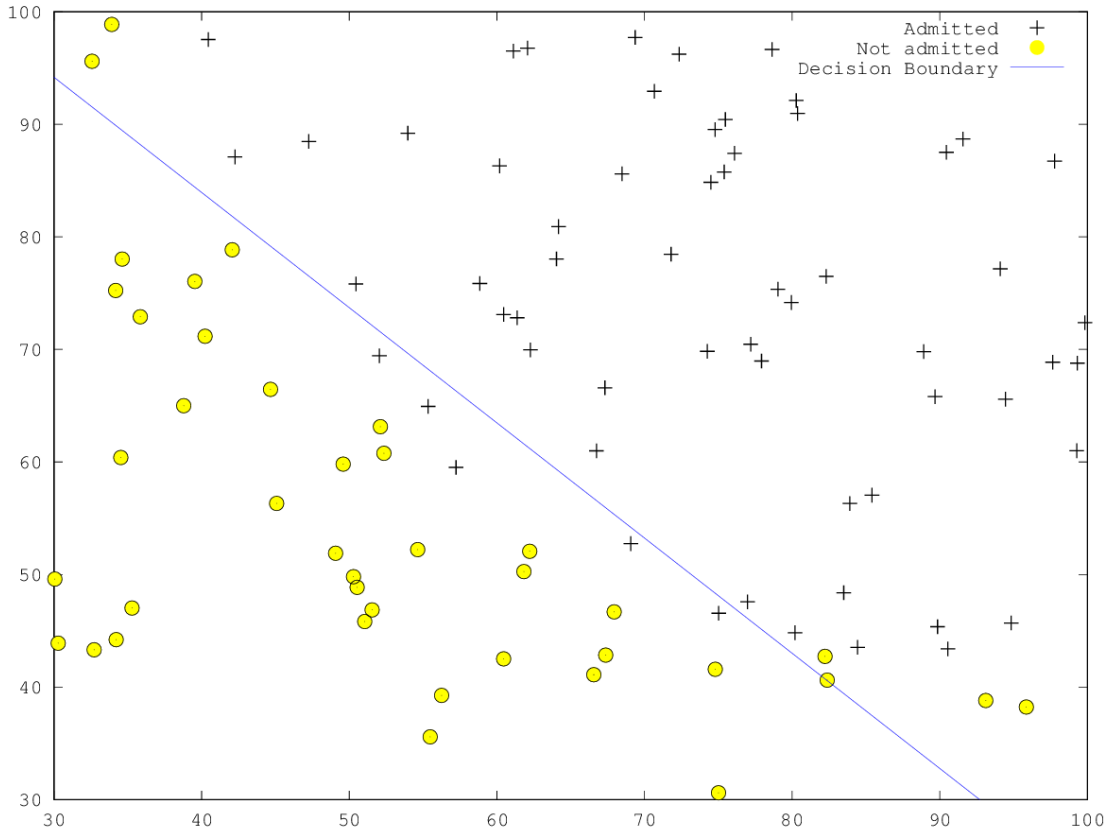

EVALUACIÓN LOGÍSTICA

Se ha implementado la siguiente función para evaluar el porcentaje de ejemplos de entrenamiento que utilizando el vector theta quedan correctamente clasificados:

```
function porcentaje = prueba(theta, X, y)
	m = length(X(:,1));

	valoresH = (theta' * X')';
	h = sigmoide(valoresH);

	h = h >= 0.5;

	porcentaje = length(find(h == y)) / m * 100;

endfunction
```

Llamando a porcentaje(tehta, X, y) al final del código de la parte Cálculo y representación, se obtiene que el 89% de datos han sido correctamente clasificados, lo que es un valor bastante aceptable, teniendo en cuenta las propias anomalías existentes en los casos de entrenamiento.

PARTE 2

FUNCIÓN DE COSTE Y GRADIENTE

```
function [J, grad] = coste2(theta, X, Y, lambda)
	warning("off", "Octave:broadcast");
	m = length(X(:,1));
	valoresH = (theta' * X')';
	h = sigmoide(valoresH);
	# Sumandos
	a = (0.-Y) .* log(h) .- ((1 .- Y) .* log(1 .- h));
	# Theta cuadrado
	t = theta .^ 2;

	J = (1/m) * sum(a) + ((lambda / m / 2) * sum(t));

	# Sumandos
	a = (h .- Y) .* X;
	# Poner a cero para no incluir el primero
	theta(1) = 0;

	grad = (1/m * sum(a)) .- ((lambda/m) .* theta)';

	warning("on", "Octave:broadcast");

endfunction
```

CÓDIGO PARA LOS CÁLCULOS Y REPRESENTACIÓN

```
# Leer datos
s = load("ex2data2.txt");
X = s(:,1:2);
y = s(:,3);
m = length(X(:,1));
# Mapear datos de entrenamiento
out = mapFeature(X(:,1),X(:,2));

# Valores de prueba de lambda
lambdaVals = [100, 50, 25, 10, 5, 3, 1, 0.5, 0.05, 0.005];
resultado = [];
for lambda = lambdaVals
	# Resetear valores de theta para cada iteración
	thetaIni = zeros(length(out(1,:)),1);
	# Calcular coste y gradiente
	[J, grad] = coste2(thetaIni, out, y, lambda);

	opciones = optimset ('Gradobj', 'on', 'MaxIter', 400);
	[theta, cost] = fminunc (@(t)(coste2(t, out, y, lambda)), thetaIni,
opciones);
	# Rrepresentación gráfica
	plotDecisionBoundary(theta, out, y, lambda);
	print(["pruebaLambda", num2str(lambda), ".png"], "-dpng");
	# Guardar métricas
	porcentaje = prueba(theta, out, y);
	aux.lambda = lambda;
	aux.cost = cost;
	aux.porcentaje = porcentaje;
	resultado = [resultado, aux];
endfor
# Guardar datos en archivo
for i = 1:length(lambdaVals)
	r = resultado(i);
	save resultado -append r;
endfor
```

El anterior código calcula, para distintos valores del parámetro lambda, los valores del vector theta que mejor se ajustan a los ejemplos de entrenamiento, según el valor lambda; mientras va guardando la representación gráfica, el coste y el porcentaje de cada valor de lamdba, para luego analizar dichos valores.

Nota: se modificó mínimamente `plotDecisionBoundary` para que muestre el valor de la lamdba usada en la gráfica

PRUEBAS REALIZADAS

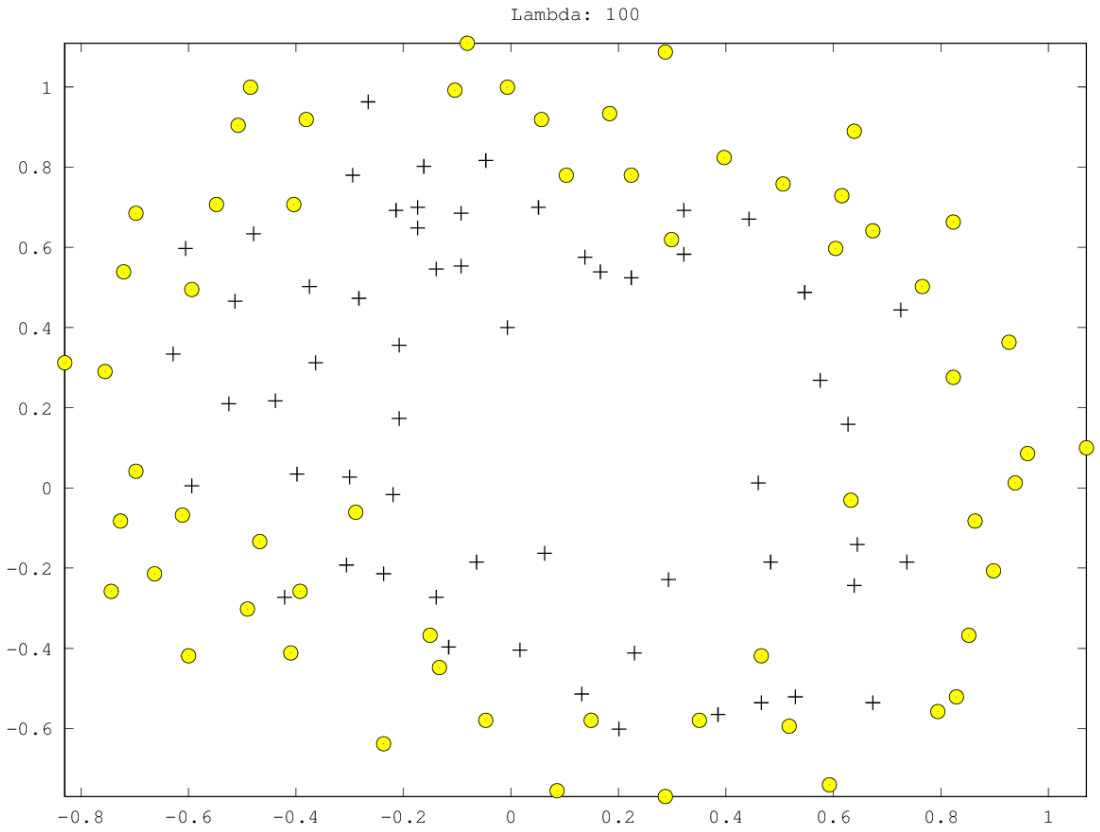

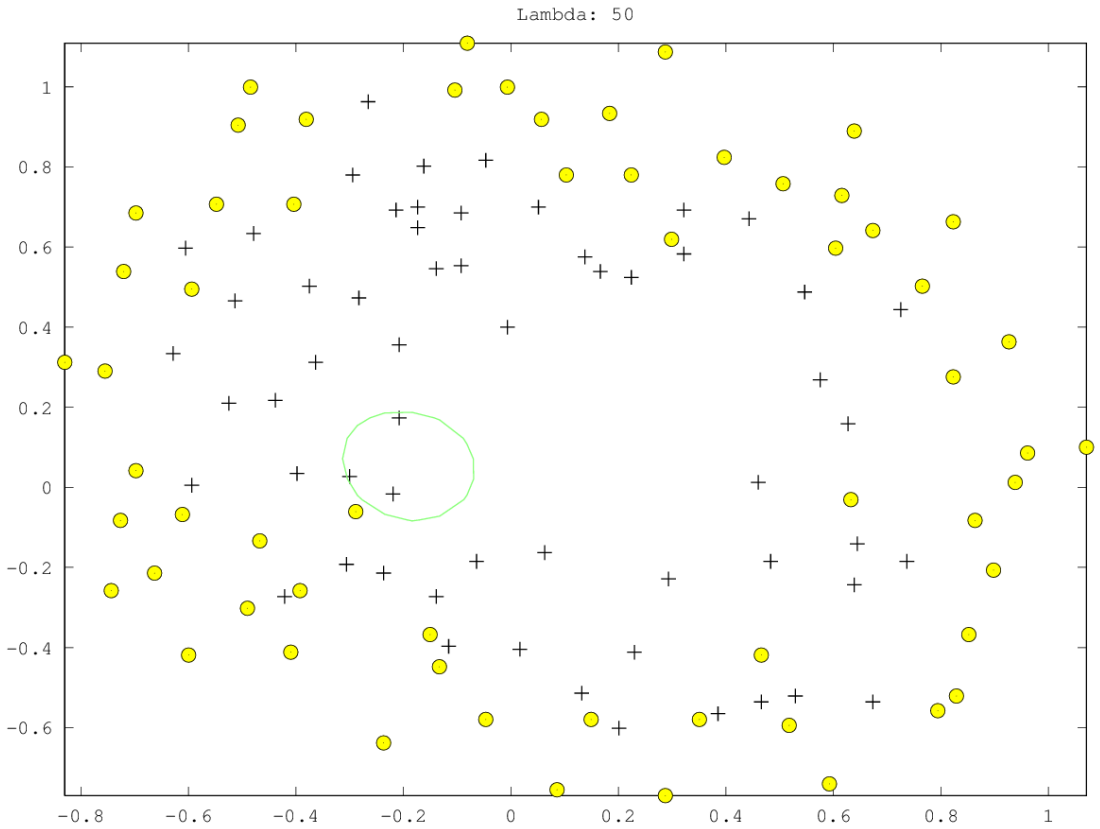

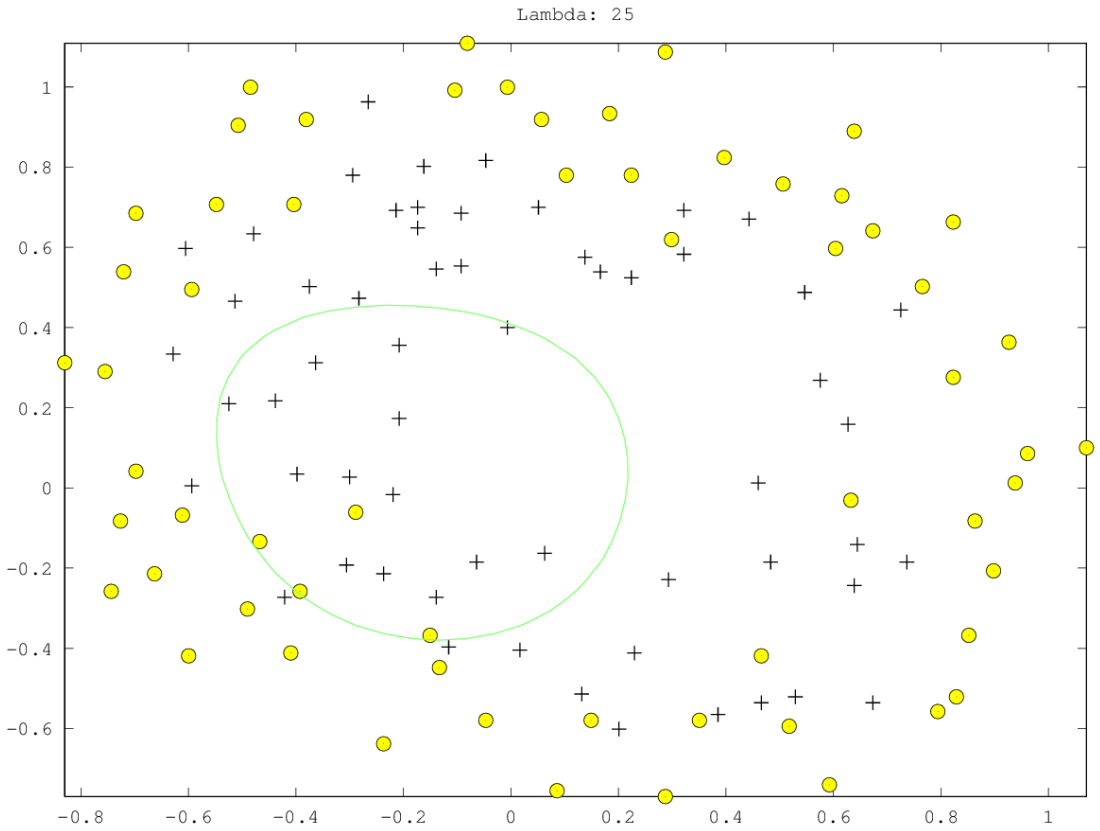
Lambda: 25
1
0.8
0.6
0.4
0.2
0
-0.2
-0.4
-0.6
-0.8
-0.6
-0.4
-0.2
0
0.2
0.4
0.6
0.8
1

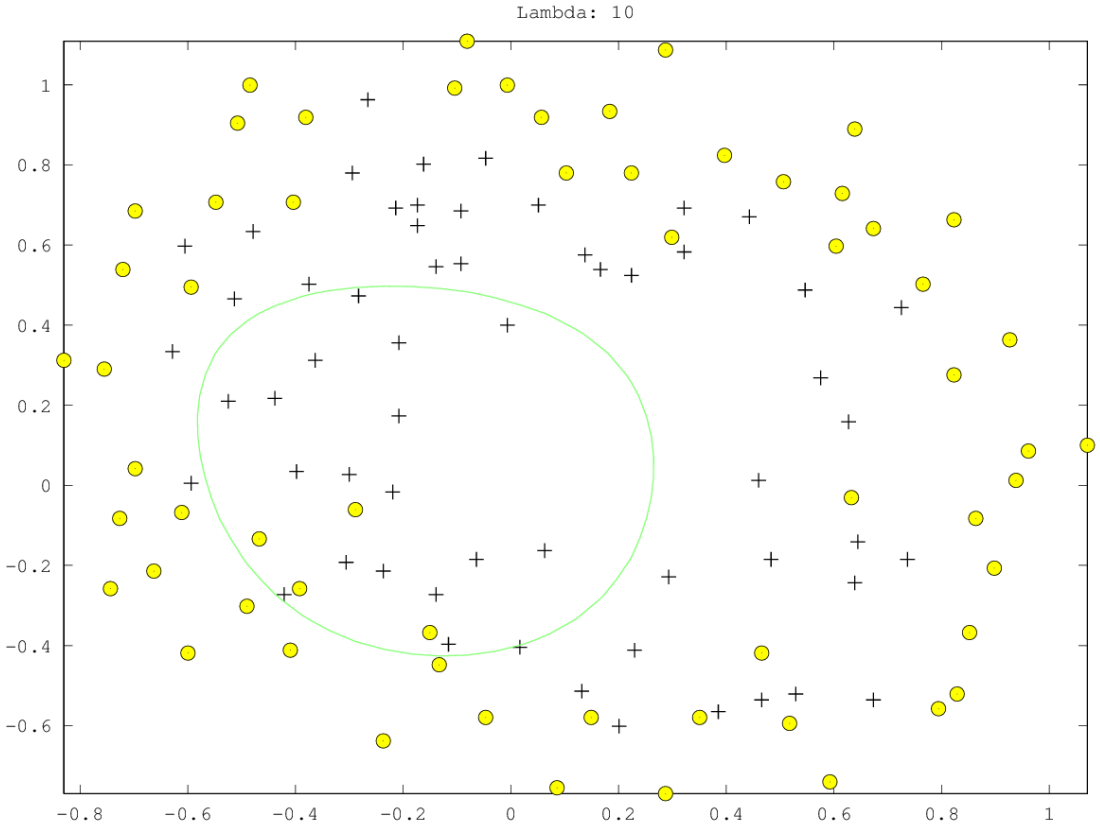
Lambda: 10
1
0.8
0.6
0.4
0.2
0
-0.2
-0.4
-0.6
-0.8
-0.6
-0.4
-0.2
0
0.2
0.4
0.6
0.8
1

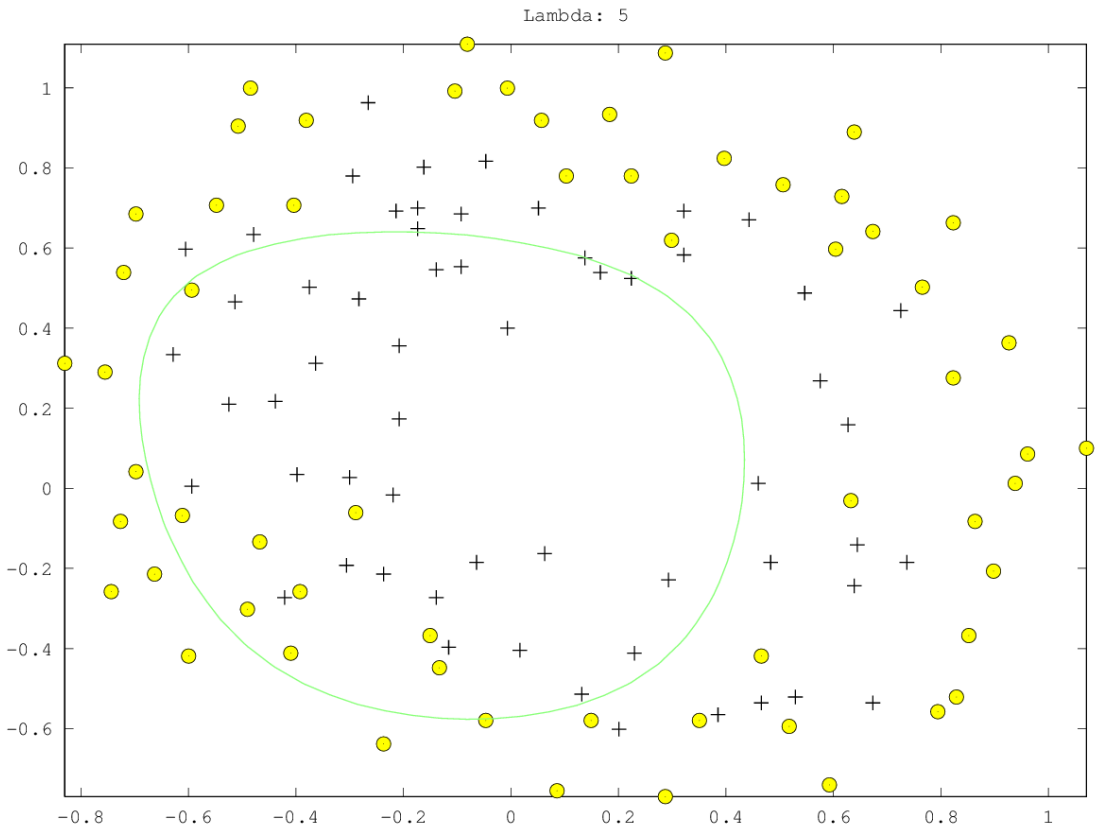
Lambda: 5
1
0.8
0.6
0.4
0.2
0
-0.2
-0.4
-0.6
-0.8
-0.6
-0.4
-0.2
0
0.2
0.4
0.6
0.8
1

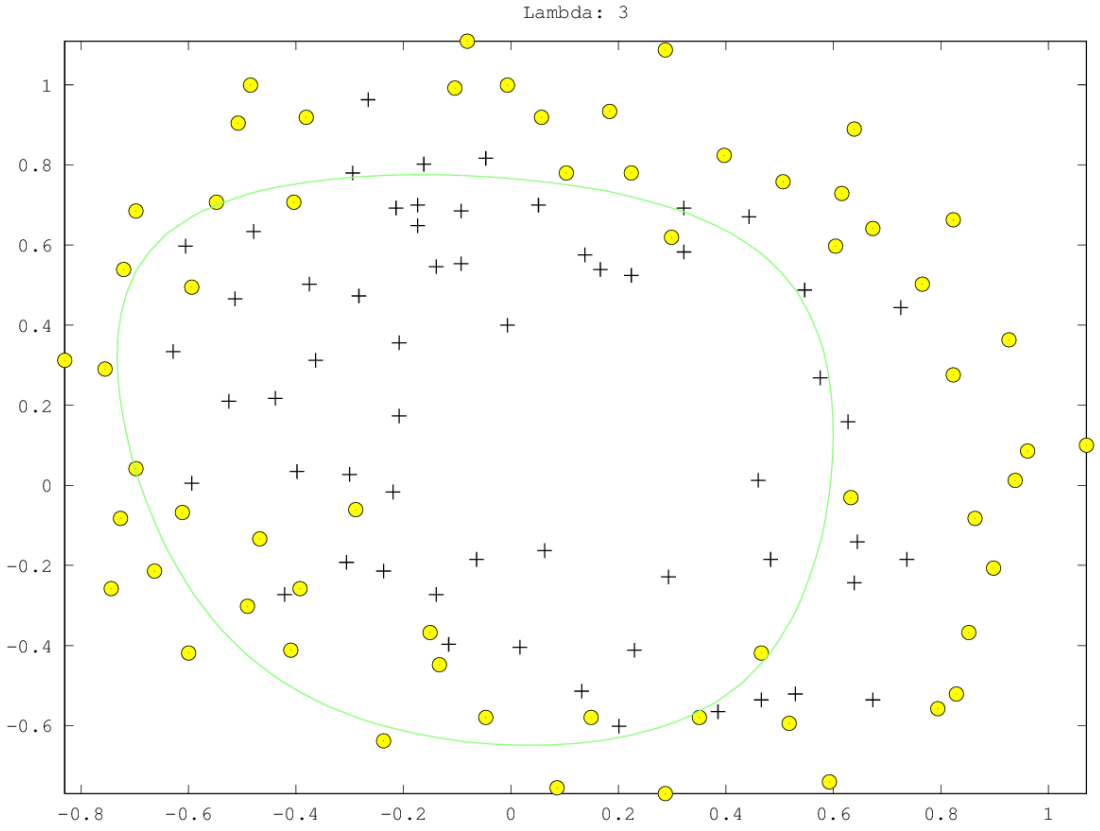
Lambda: 3
1
0.8
0.6
0.4
0.2
0
-0.2
-0.4
-0.6
-0.8
-0.6
-0.4
-0.2
0
0.2
0.4
0.6
0.8
1

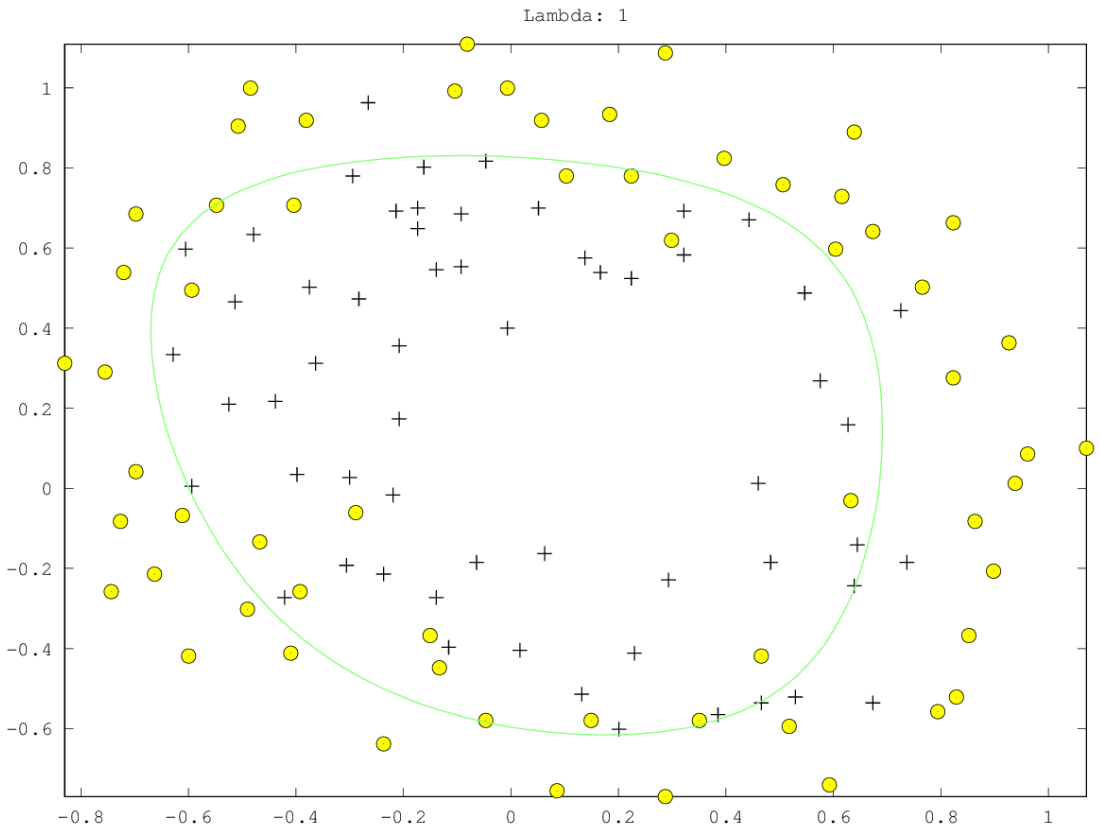
Lambda: 1
1
0.8
0.6
0.4
0.2
0
-0.2
-0.4
-0.6
-0.8
-0.6
-0.4
-0.2
0
0.2
0.4
0.6
0.8
1

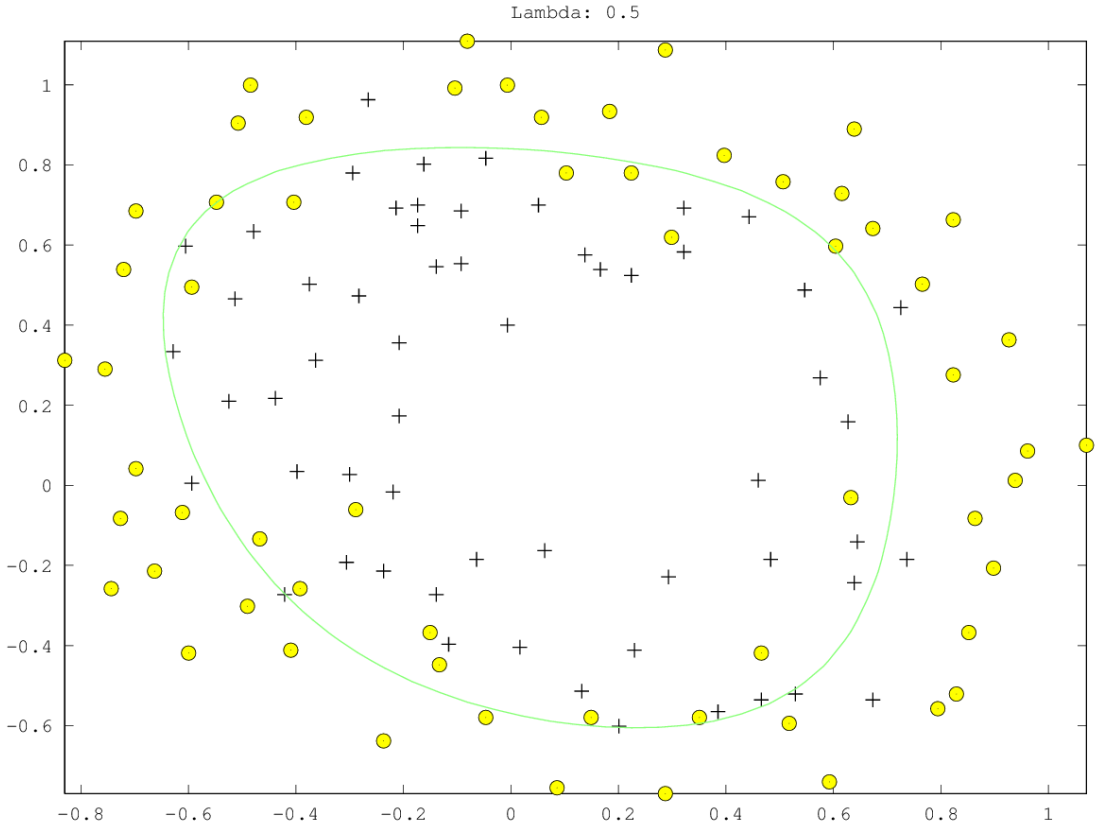
Lambda: 0.5
1
0.8
0.6
0.4
0.2
0
-0.2
-0.4
-0.6
-0.8
-0.6
-0.4
-0.2
0
0.2
0.4
0.6
0.8
1

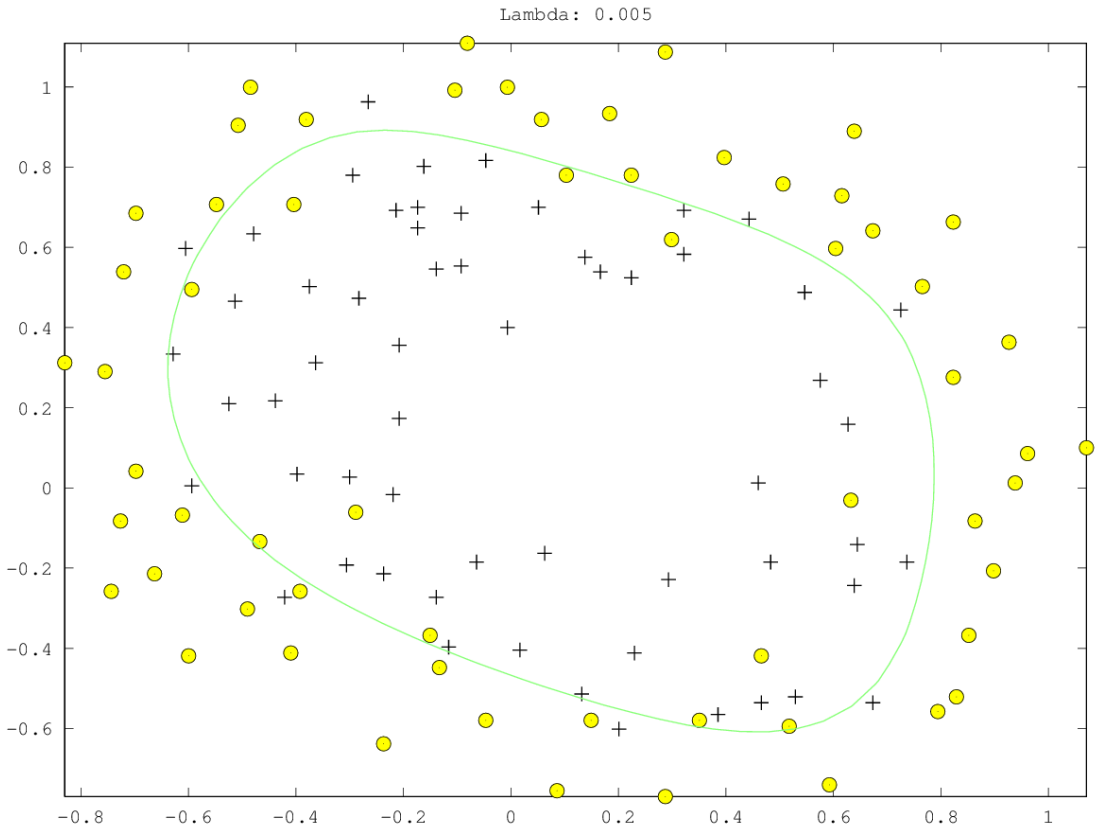
Lambda: 0.005
1
0.8
0.6
0.4
0.2
0
-0.2
-0.4
-0.6
-0.8
-0.6
-0.4
-0.2
0
0.2
0.4
0.6
0.8
1

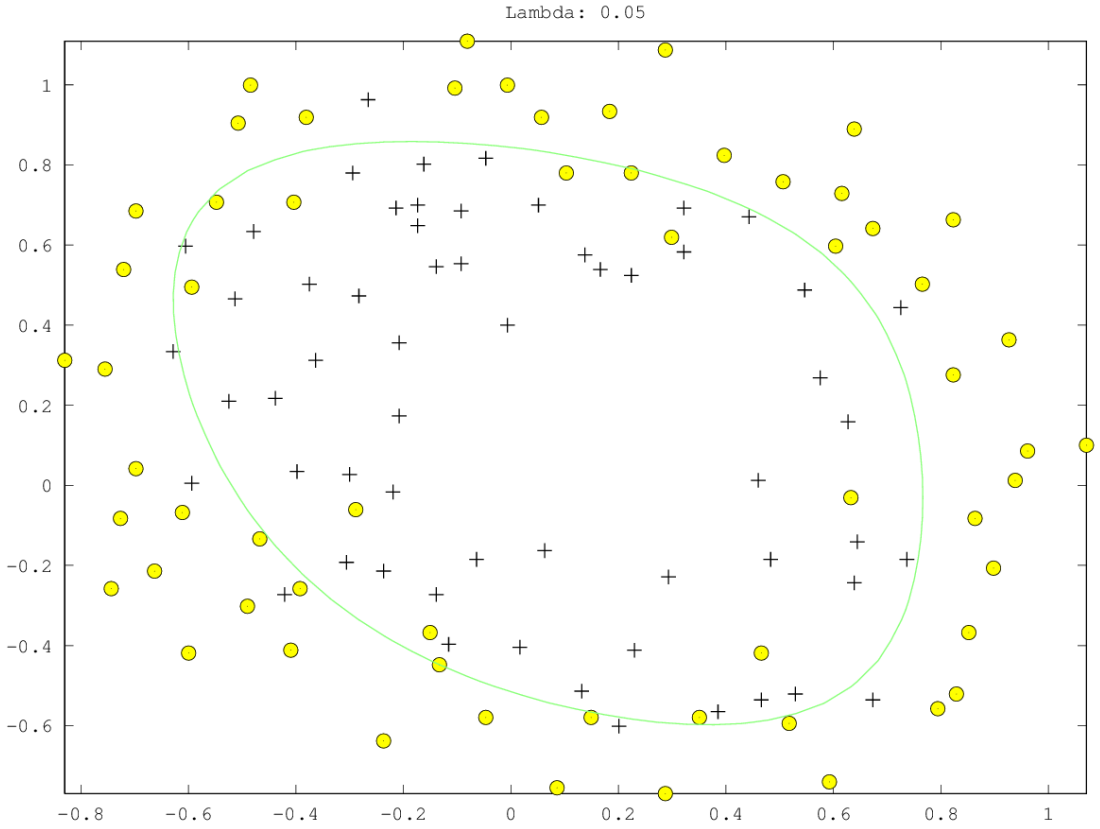
Lambda: 0.05
1
0.8
0.6
0.4
0.2
0
-0.2
-0.4
-0.6
-0.8
-0.6
-0.4
-0.2
0
0.2
0.4
0.6
0.8
1

Con las gráficas anteriores, se observa que para valores pequeños de lambda se obtiene una mejor aproximación. Esto queda también reflejado en la siguiente gráfica, que representa la precisión obtenida respecto de la lambda usada: