APRENDIZAJE AUTOMÁTICO

Práctica 6

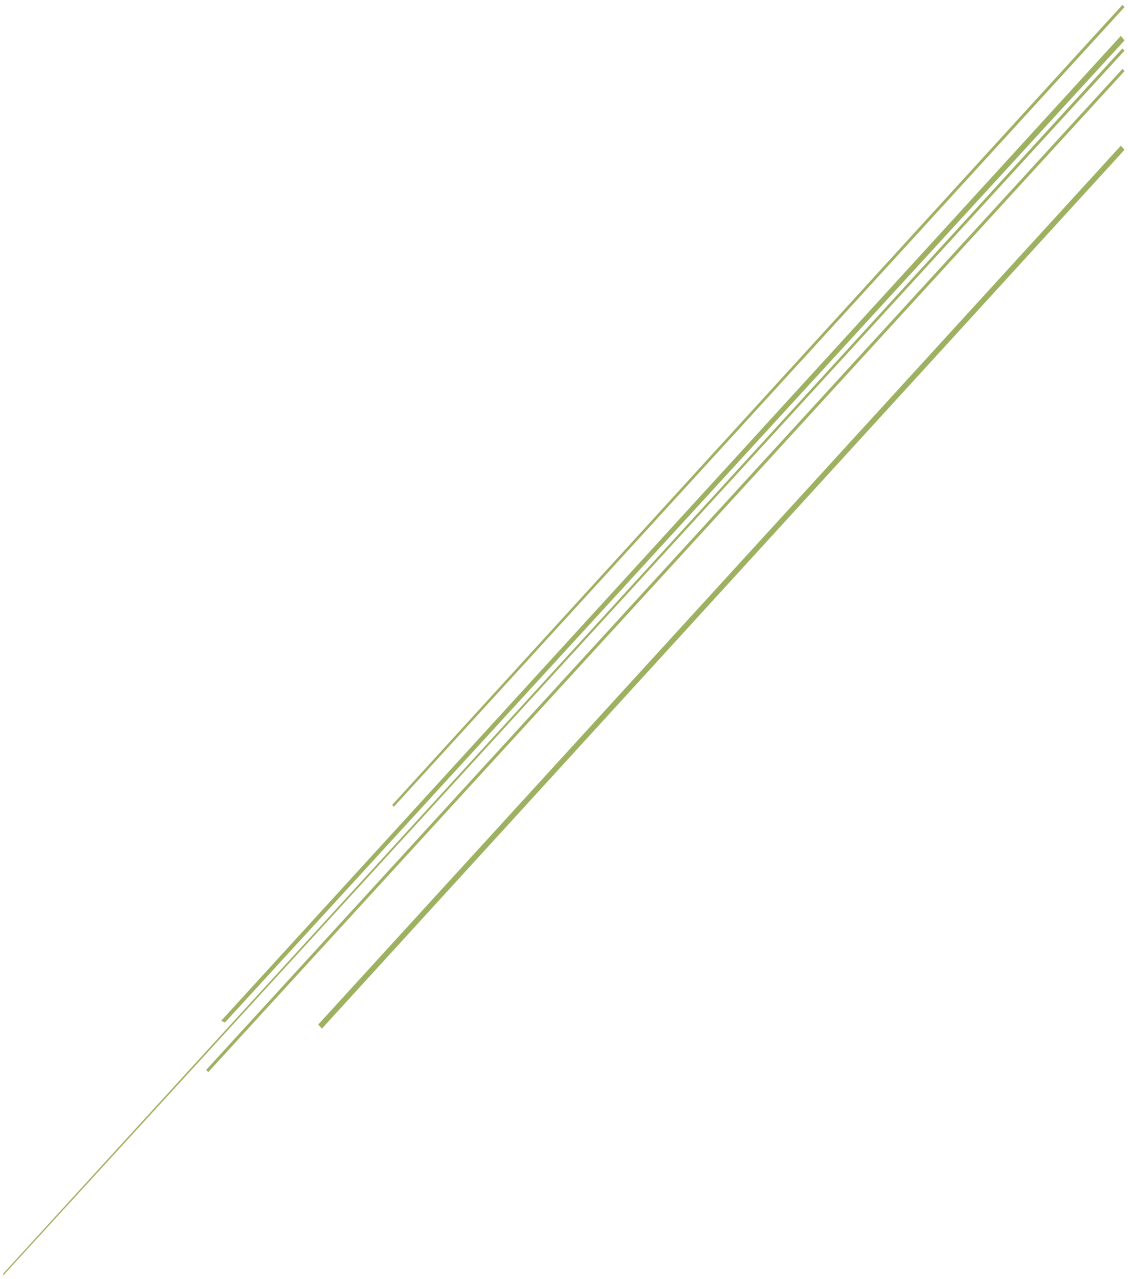

Miguel Ascanio Gómez

Esther Ávila Benito

En esta práctica se ha estudiado el uso del clasificador *Support Vector Machines* y lo hemos aplicado a un ejemplo de detección de correo *spam*.

SUPPORT VECTOR MACHINES

KERNEL LINEAL

```
clear;
load ex6data1.mat;

C = 1;

model = svmTrain(X, y, C, @linearKernel, 1e-3, 20);
visualizeBoundaryLinear(X,y,model);

title("C = 1");
print("-dpng", "Parte1_C1.png");

C = 100;

model = svmTrain(X, y, C, @linearKernel, 1e-3, 20);
visualizeBoundaryLinear(X,y,model);
title("C = 100");
print("-dpng", "Parte1_C100.png");


load("ex3data1.mat");
m = size(X, 1);
```

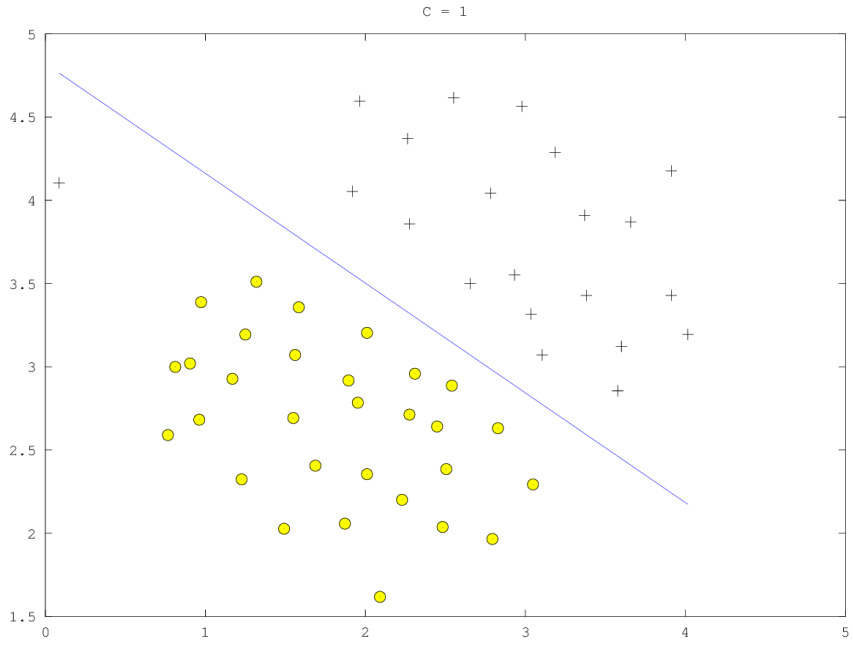

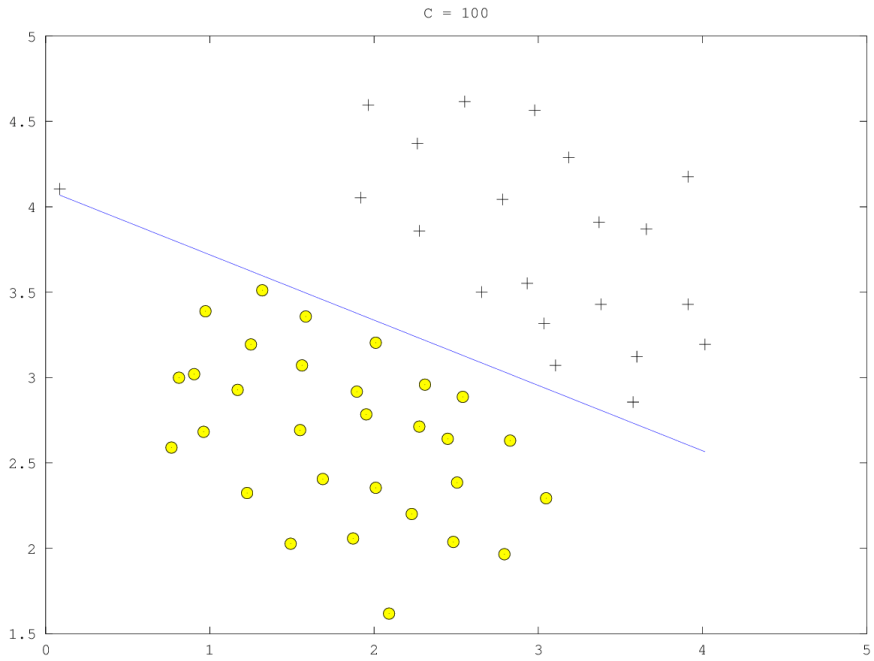

KERNEL GAUSSIANO

Cálculo del *kernel gaussiano* con el que se entrenara una SVM para la clasificación de los datos contenidos en *ex6data2.mat*.

```
function sim = gaussianKernel(x1, x2, sigma)

sumandos = (x1 .- x2).^2;
sim = exp(-(sum(sumandos) / (2 * (sigma ^2))));

endfunction
```

Se emplea el kernel gaussiano con *C* = 1 y *sigma* = 0.1

```
clear;
load ex6data2.mat;

C = 1;
sigma = 0.1;

model = svmTrain(X, y, C, @(x1, x2) gaussianKernel(x1, x2, sigma));
visualizeBoundary(X,y,model);
```

ELECCIÓN DE LOS PARÁMETROS *C* Y *SIGMA*

Se seleccionan los valores de *C* *sigma* para la clasificación de los datos contenidos en ex6data3.mat. El cálculo de estos parámetros se realiza para los valores del conjunto 0.01, 0.03, 0.1, 0.3, 1, 3, 10, 30.

```
load ex6data3.mat;

valores = [0.01, 0.03, 0.1, 0.3, 1, 3, 10, 30];

i = 1;
j = 1;

porcentajes = [];

for C = valores
i
j = 1;
for  sigma = valores
j
      model = svmTrain(X, y, C, @(x1, x2) gaussianKernel(x1, x2, sigma));
      ypred = svmPredict(model, Xval);

      dataSave(i,j).C = C;
      dataSave(i,j).sigma = sigma;
      dataSave(i,j).model = model;
      dataSave(i,j).porcentaje = size(find(yval == ypred))(1) / size(yval)(1) * 100;
      j = j+1;
endfor
i = i+1;
endfor

save dataSavePr666 dataSave;
```

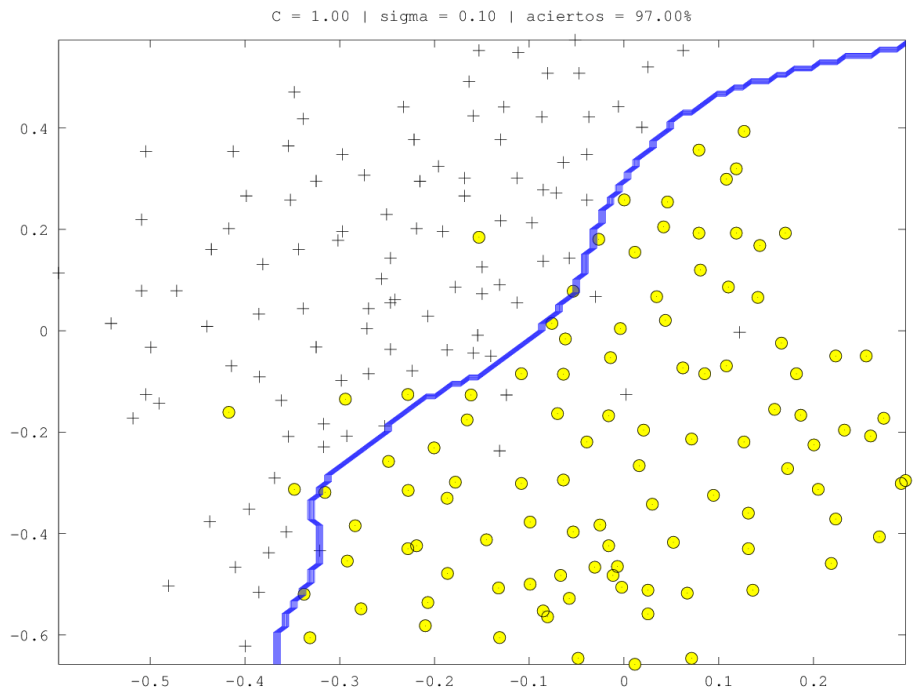

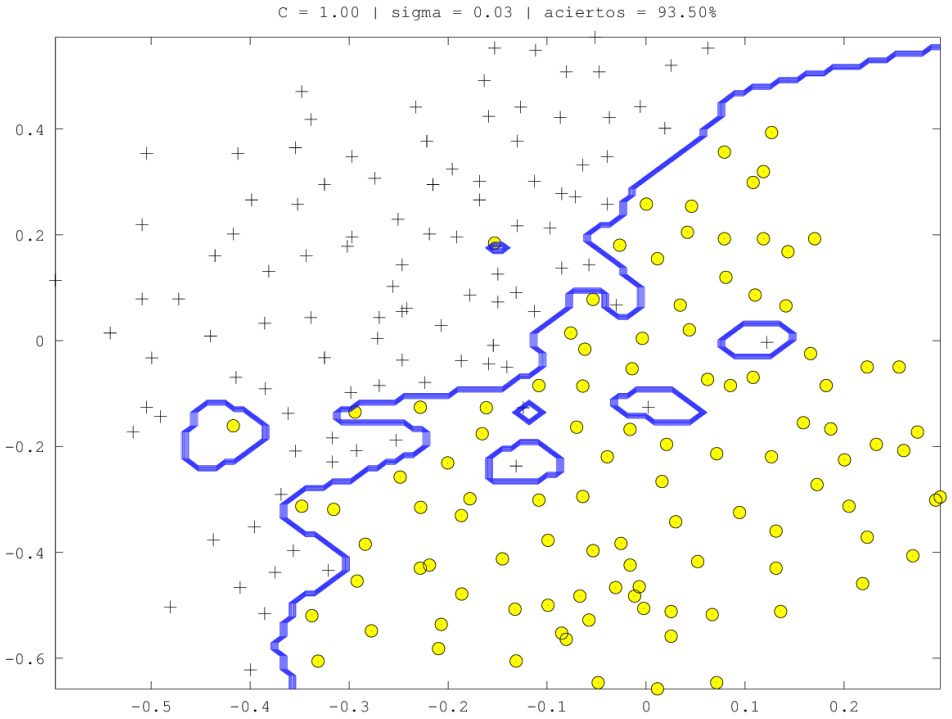

Apreciamos que, para el mismo valor de *C,* a menor valor de *sigma,* tiene a sobreajustarse.

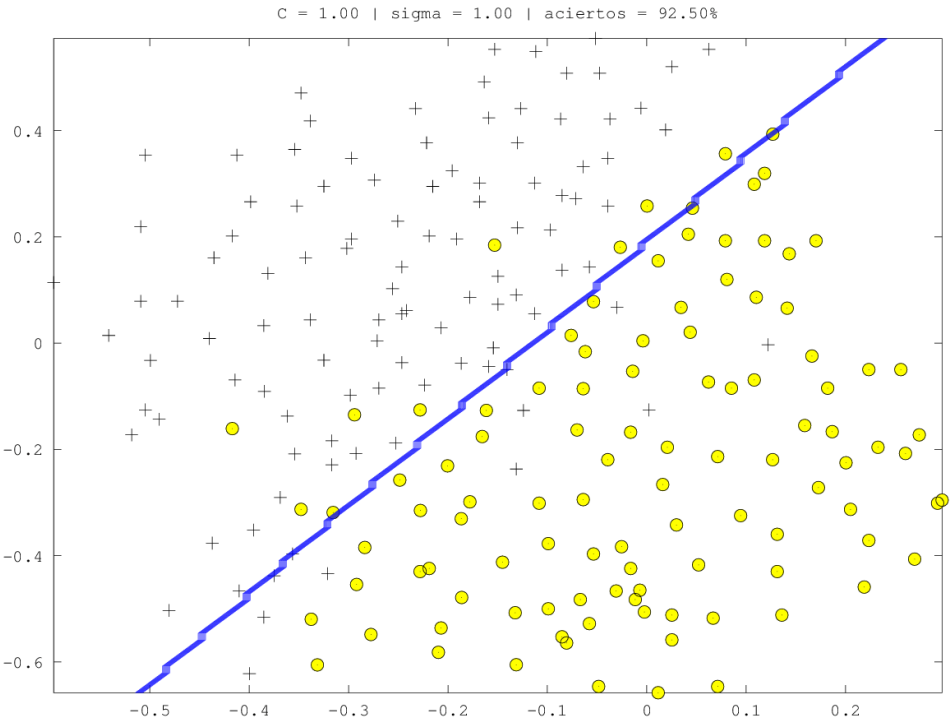

En cambio, para un valor fijo de *sigma*, el sobreajuste aumenta con el mayor valor de *C.*

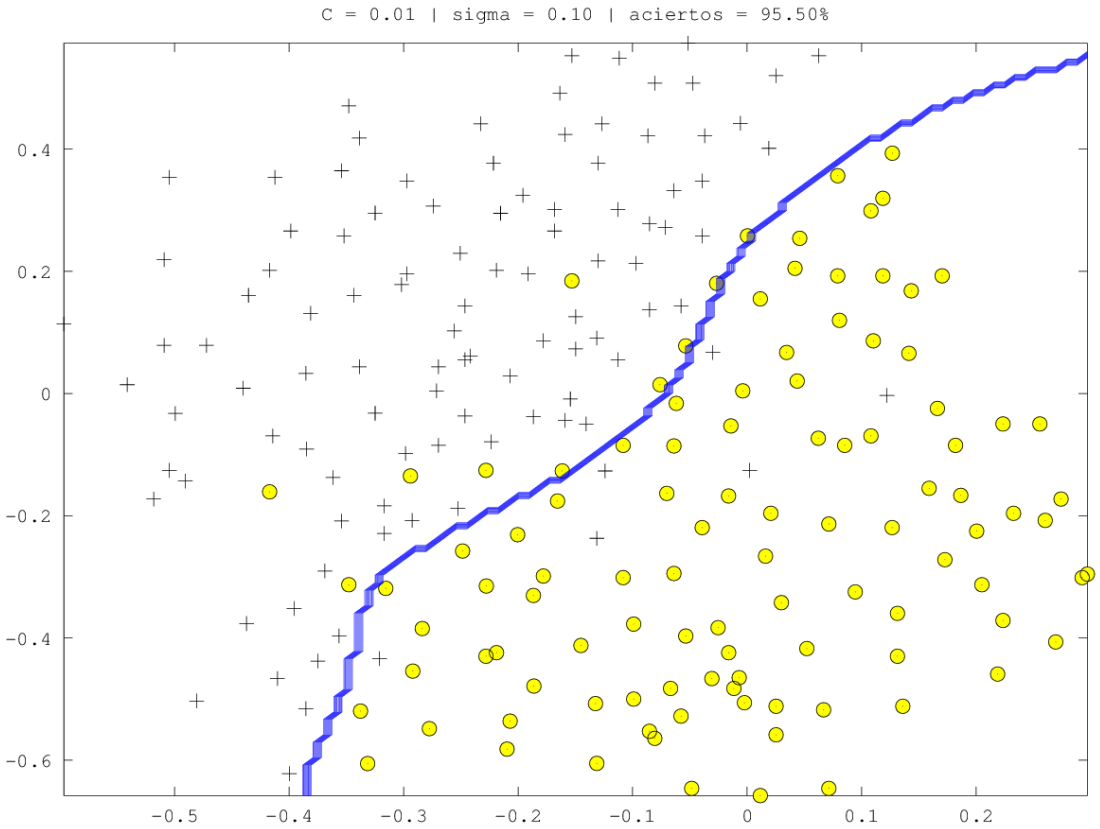
C = 0.01 | sigma = 0.10 | aciertos = 95.50%
0.4
0.2
0
-0.2
-0.4
-0.6
-0.5
-0.4
-0.3
-0.2
-0.1
0
0.1
0.2

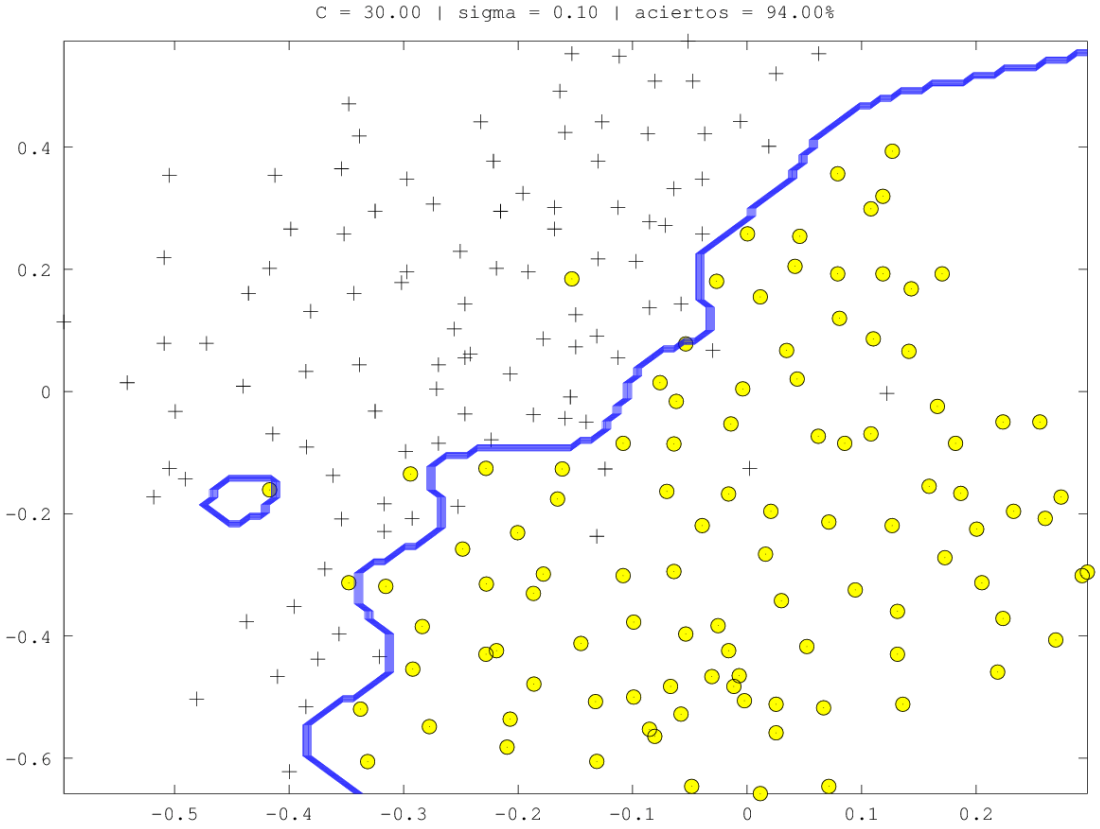
C = 30.00 | sigma = 0.10 | aciertos = 94.00%
0.4
0.2
0
-0.2
-0.4
-0.6
-0.5
-0.4
-0.3
-0.2
-0.1
0
0.1
0.2

FILTRO DE SPAM

Lo primero es cargar el vocabulario en un formato comprensible y optimizado para Octave:

```
function vocabulario = cargaVocab()

vocablist = getVocabList;

for i = 1:length(vocablist)
	vocabulario.(vocablist {i}) = i;
endfor

endfunction;
```

Lo siguiente es procesar los emails con el diccionario anterior. Como este proceso es bastante lento, conviene guardar los datos generados:

```
vocabulario = cargaVocab();
num_easy_ham = 2551;
num_hard_ham = 250;
num_spam = 500;

for i = 1:num_hard_ham
	nombreArchivo = sprintf('hard_ham/%.4d.txt', i);
	file_contents = readFile(nombreArchivo);
	email = processEmail(file_contents);

	X_hard_ham(i,:) = getX(email, vocabulario,tamVocabulario);

	if (mod(i, 25) == 0) % Guardar datos intermedios
		fprintf("Saving X_hard_ham\nIteración: %d\n", i);
		save X_hard_ham X_hard_ham;
	endif
endfor
save X_hard_ham X_hard_ham;
```

(…)
Se procede de manera análoga a los otros tipos de email

```
function x = getX(email, vocab, tamVocabulario)

	x = zeros(1, tamVocabulario);

	while ~isempty(email)
	[str, email] = strtok(email, [' ']);
	% procesa str
		if (isfield(vocab, str))
			x(getfield(vocab, str)) = 1;
		endif
	end

endfunction
```

El siguiente código es el utilizado para entrenar la SVM.

CARGA DE LOS DATOS Y SELECCIÓN DE PARÁMETROS

```
clear;
save_inter_data = true;
```

```
num_iteraciones_totales = 3;

num_easy_ham = 2551;
num_hard_ham = 250;
num_spam = 500;

% Asignar división ejemplos de entrenamiento/validación/test
parte_train = 0.8;
parte_val = 0.2;
parte_test = 0;

if (parte_train + parte_val + parte_test > 1)
      error("La suma de las divisiones de ejemplos de entrenamiento/validación/test\nes mayor
que 1");
endif
if(parte_train + parte_val + parte_test < 1)
      warning("La suma de las divisiones de ejemplos de entrenamiento/validación/test\nes
menor que 1, no se utilizarán todos los casos");
endif

% Asignar parte a tomar de easy/hard/spam del total de cada tipo
parte_easy = 1;
parte_hard = 1;
parte_spam = 1;
if (parte_easy > 1 || parte_hard > 1 || parte_spam > 1)
      error("No puede haber una parte mayor que 1");
endif
if (parte_easy < 1 || parte_hard < 1 || parte_spam < 1)
      warning("No se están utilizando todos los casos de entrenamiento\nal no cojer todo el
conjuto de spam/easy/hard");
endif
cargaDatos;
disp("\n*************************************************************************\n");
printf("Entrenando SVM con %d permutaciones de los ejemplos de entrenamiento\ndivididos %.2f%%
como entrenamiento y %.2f%% como validación\ndando un total de %d ejemplos de entrenamiento y
%d de validacion\nconteniendo a su vez en %.2f%% de los easy_ham, %.2f%% de los hard_ham y
%.2f%% de los spam.\nUtilizando los siguientes parámetros:\n",
num_iteraciones_totales,parte_train*100, parte_val*100,num_train, num_val, parte_easy*100,
parte_hard*100, parte_spam*100);

valoresC = [8]
valoressigma = [1.4]
```

CODIGO DE CARGA DATOS

```
load X_spam;
load X_easy_ham;
load X_hard_ham;

num_easy_ham = 2551;
num_hard_ham = 250;
num_spam = 500;

% Mezclar (se explica más adelante)
X_easy_ham = X_easy_ham(randperm(size(X_easy_ham)(1)),:);
```

```
X_hard_ham = X_hard_ham(randperm(size(X_hard_ham)(1)),:);
X_spam = X_spam(randperm(size(X_spam)(1)),:);

% Seleccionar cuantos (importante después de mezclar)
num_easy_ham = floor(num_easy_ham * parte_easy);
num_hard_ham = floor(num_hard_ham * parte_hard);
num_spam = floor(num_spam * parte_spam);

% Seleccionar el numero deseado de cada
X_spam = X_spam(1:num_spam, :);
X_hard_ham = X_hard_ham(1:num_hard_ham, :);
X_easy_ham = X_easy_ham(1:num_easy_ham, :);

getXY;
```

CODIGO DE GETXY

```
train_easy_ham = floor(num_easy_ham * parte_train);
train_hard_ham = floor(num_hard_ham * parte_train);
train_spam = floor(num_spam * parte_train);

val_easy_ham = floor(num_easy_ham * parte_val);
val_hard_ham = floor(num_hard_ham * parte_val);
val_spam = floor(num_spam * parte_val);

% Separar entrenamiento/validacion de cada tipo %
separa;

% Unir en una X por training/validacion %
num_train = train_easy_ham + train_hard_ham + train_spam;
num_val = val_easy_ham + val_hard_ham + val_spam;

X_train = [X_tra_eh; X_tra_hh; X_tra_spam];
% Para las y, marcamos como 0 (no spam) los easy y hard, y como 1 los spam
Y_train = [zeros(1,train_easy_ham),zeros(1,train_hard_ham),ones(1,train_spam)];
% Mezclamos otra vez para que no queden juntos los easy/hard/spam
perm = randperm(size(X_train)(1));
X_train = X_train(perm, :);
Y_train = Y_train(perm)';
(…)
```

Para los ejemplos de validación es análogo

CODIGO DE SEPARA

```
X_tra_eh = X_easy_ham(1:train_easy_ham,:);
X_val_eh = X_easy_ham(train_easy_ham+1:train_easy_ham+val_easy_ham,:);

X_tra_hh = X_hard_ham(1:train_hard_ham,:);
X_val_hh = X_hard_ham(train_hard_ham+1:train_hard_ham+val_hard_ham,:);

X_tra_spam = X_spam(1:train_spam,:);
X_val_spam = X_spam(train_spam+1:train_spam+val_spam,:);
```

Los códigos anteriores se encargan de cargar los datos para el entrenamiento, juntándolos todos en las matrices de X_train, Y_train, X_val e Y_val, de tal forma que los ejemplos de entrenamiento y validación queden bien distribuidos: hay la misma proporción, indicada como constante, de spam en X_train e X_val, al igual que de easy_ham y hard_ham.

PARTE DE ENTRENAMIENTO

```
for k = 1:num_iteraciones_totales
printf("Cargando los datos de la iteracion k = %d\n", k);
cargaDatos;
disp("Datos cargados!\n");
i = 1;
	for C = valoresC
	j = 1;
		for sigma = valoressigma
			printf("Iteracion k=%d, i=%d, j=%d\ncon C=%d sigma=%d\n",k,i,j,C,sigma);

			model = svmTrain(X_train, Y_train, C, @(x1, x2) gaussianKernel(x1, x2,
sigma));
			ypred = svmPredict(model, X_val);
			if (save_inter_data)
				dataSave(i,j).C = C;
				dataSave(i,j).sigma = sigma;
				dataSave(i,j).model = model;
				% Porcentaje de aciertos
				dataSave(i,j).porcentaje = size(find(Y_val == ypred))(1) /
size(Y_val)(1) * 100;
				% Porcentaje, de los errores, que se predijo spam (y no lo era)
				dataSave(i,j).porcentajePredErroneasSpam = size(find(ypred(find(ypred
!= Y_val))==1))(1) / size(ypred(find(ypred!=Y_val)))(1);
			endif
			j = j+1;
		endfor
		i = i+1;
	endfor
endfor
```

Inicialmente, los datos de entrenamiento no se mezclaban y se obtuvieron los siguientes resultados:
Una vez entrenado con los valores de sigma y C
valores = [0.01, 0.03, 0.1, 0.3, 1, 3, 10, 30];
arrayPorcentajesVal =
C\s

22.475	22.475	22.657	66.606	55.869	70.792	71.429	28.025
22.475	22.475	22.657	66.697	57.507	70.246	71.793	29.299
22.475	22.475	22.657	66.697	57.052	69.882	71.702	27.934
22.475	22.475	22.657	66.697	57.052	69.518	71.429	28.571
22.475	22.475	22.657	66.697	56.506	75.705	81.984	28.753
22.475	22.475	22.657	66.697	58.417	80.801	83.167	29.026
22.475	22.475	22.657	66.697	58.417	82.257	82.348	30.482
22.475	22.475	22.657	66.697	58.417	82.257	85.441	28.662

Se observa que el maximo está en C30 sigma10, sin embargo para X_test el porcentaje es de 65,5%

arrayPorcentajesTest =
C\s

17.951	17.951	20.036	45.422	38.259	56.392	51.859	20.036
17.951	17.951	20.036	45.422	38.622	55.848	54.216	19.674
17.951	17.951	20.036	45.422	38.622	55.576	54.125	19.130
17.951	17.951	20.036	45.422	38.622	55.848	53.762	19.402
17.951	17.951	20.036	45.422	37.625	62.647	63.191	19.583
17.951	17.951	20.036	45.422	38.622	66.818	62.194	19.946
17.951	17.951	20.036	45.422	38.622	68.359	62.919	20.218
17.951	17.951	20.036	45.422	38.622	68.359	65.549	18.858

prueba con C=linspace(3,30,8) sigma=(3,30,8)

arrayPorcentajesVal =
C\s

80.801	79.072	82.712	73.066	55.687	39.490	32.302	29.117
81.893	80.255	80.528	70.519	58.872	47.316	36.397	27.571
82.257	81.074	80.164	68.517	54.868	45.769	39.035	30.664
82.257	82.075	81.711	68.517	52.684	42.857	36.943	33.303
82.257	82.530	81.802	68.881	53.321	41.310	35.669	32.029
82.257	82.803	82.530	70.337	54.504	40.764	34.304	30.209
82.257	83.167	82.712	71.065	54.231	41.947	33.667	29.572
82.257	83.439	83.348	71.884	55.687	42.766	33.485	28.662

arrayPorcentajesTest =
C\s 3.000 6.8571 10.7143 14.5714 18.4286 22.2857 26.1429 30.0000

66.818	66.727	60.925	47.325	31.460	23.481	21.215	19.946
68.087	64.098	59.655	44.062	33.092	25.929	22.031	19.583
68.359	65.186	60.381	42.792	30.553	25.748	22.393	20.127
68.359	65.095	61.378	42.974	30.281	24.932	21.396	20.399
68.359	65.005	62.194	43.427	30.281	24.116	20.943	19.946
68.359	65.277	63.101	44.152	30.734	23.935	20.671	19.130
68.359	65.277	63.282	45.240	31.550	24.751	20.490	18.767
68.359	65.549	64.007	46.510	32.366	25.113	20.852	18.858

prueba con C=linspace(1,10,8) sigma=linspace(0.2, 10, 8);

arrayPorcentajesVal =

C=	1.0000	2.2857	3.5714	4.857	6.1429	7.4286	8.7143	10.0000

C\s	0.2000	1.6000	3.0000	4.4000	5.8000	7.2000	8.6000	10.000
	33.485	60.510	75.705	71.520	74.795	80.346	82.439	81.893
	33.485	68.699	80.619	75.159	76.342	80.710	82.985	83.258
	33.485	68.699	80.983	74.704	75.796	80.164	82.803	82.803
	33.485	68.699	81.711	74.704	76.524	79.618	82.803	82.530
	33.485	68.699	81.893	74.704	76.706	80.710	82.348	82.621
	33.485	68.699	82.348	74.977	76.888	81.802	82.621	82.439
	33.485	68.699	82.257	75.159	76.797	82.166	82.985	81.711
	33.485	68.699	82.257	75.159	76.797	82.348	83.530	82.439

arrayPorcentajesTest =

C=	1.0000	2.2857	3.5714	4.857	6.1429	7.4286	8.7143	10.0000

C\s	0.2000	1.6000	3.0000	4.4000	5.8000	7.2000	8.6000	10.000
	33.001	42.067	62.647	63.554	63.554	65.186	65.911	63.101
	33.001	48.232	67.543	66.364	65.911	66.727	64.642	63.373
	33.001	48.232	66.818	66.727	64.551	66.092	65.095	62.103
	33.001	48.232	67.180	66.546	64.098	64.642	65.095	62.375
	33.001	48.232	67.724	64.551	64.461	64.370	64.914	62.375
	33.001	48.232	68.359	64.733	64.642	64.007	64.642	61.922
	33.001	48.232	68.359	64.823	64.551	64.642	64.551	62.829
	33.001	48.232	68.359	64.914	64.551	65.549	64.733	62.919

Se observa una diferencia muy extraña entre los ejemplos de validación/testeo, ya que simplemente son ejemplos tomados en diferentes posiciones. Esto lleva a pensar que los ejemplos no están distribuidos de manera uniforme (de "dificultad de aprendizaje"), por lo que los mezclamos.

Viendo que al mezclar los elementos el porcentaje de validación/testeo coincide, se concluye que los datos no estaban bien distribuidos. Volvemos a probar valores para sigma y C, ahora sólo para X_Val (dist 0.5Train 0.5Val 0Test)

alores = [0.01, 0.03, 0.1, 0.3, 1, 3, 10, 30];

arrayPorcentajesVal =

22.061	22.303	31.515	77.818	78.303	89.394	87.879	68.242
22.061	22.303	31.515	77.879	78.303	88.909	87.879	73.212
22.061	22.303	31.515	77.879	78.606	88.970	87.879	73.576
22.061	22.303	31.515	77.879	78.545	89.455	88.424	71.455
22.061	22.303	31.515	77.879	78.909	92.788	91.879	71.636
22.061	22.303	31.515	77.879	80.727	94.606	94.485	44.000
22.061	22.303	31.515	77.879	80.727	94.545	92.667	59.212
22.061	22.303	31.515	77.879	80.727	94.545	91.091	57.273

Se observa que el valor óptimo de sigma aparenta estar entre 1-10. El de C en torno a 3.
Probamos para sigma = linspace(1,10,8) C = linspace(1,4,8)

arrayPorcentajesVal =

86.788	93.758	91.455	90.727	90.182	88.970	87.939	86.788
88.909	94.606	93.091	92.000	91.697	91.091	90.182	88.606
90.000	94.848	93.818	92.485	91.818	91.455	91.273	89.697
90.000	94.848	93.818	92.545	91.818	91.515	91.697	90.424
90.000	94.848	93.818	92.485	91.636	91.576	91.455	90.485
90.000	94.848	93.818	92.485	91.455	91.152	91.091	90.424
90.000	94.848	93.697	92.424	91.333	90.909	91.030	90.242
90.000	94.909	93.636	92.485	91.394	90.848	90.727	90.061

Donde se ve que el valor sigma=1.4 es muy bueno.

Sin embargo, al ejecutar varias veces el enternamiento con distintas permutaciones de los ejemplos de entrenamiento/validacion para sigma= 1,4 y C=8, se observa que los porcentajes de acierto varían hasta un 10% :

arrayPorcentajesVal =

80.000
84.667
90.485
84.727
82.061
86.424
86.788
87.273
85.091
82.364

Dichos porcentajes se han calculado con un 50% ejemplos de entrenamiento/50% datos de valicadión

porcentajes_50_50	porcentajes_30_20	porcentajes_50_20	porcentajes_80_20
80.000	81.818	87.273	86.970
84.667	82.424	81.515	86.818
90.485	81.364	85.606	91.212
84.727	84.545	89.242	88.485
82.061	86.364	88.030	90.303
86.424	92.424	85.303	90.303
86.788	84.394	84.545	88.636
87.273	77.121	86.212	88.485
85.091	79.545	84.242	90.455
82.364	84.545	86.061	90.455
	Avg 83.455	avg 85.803	avg 89.212
	std 4.1591	std 2.1570	std 1.5498

Se observa que para un número fijo de número de elementos de validación, aumentar el número de ejemplos de entrenamiento ayuda a aumentar el porcentaje de aciertos sobre los ejemplos de validación, y lo más importante, la salida depede menos de que ejemplos se han seleccioando.

Porcentaje, en las predicciones erróneas, en las que se predijo spam:

```
> for i=1:k
> model = datosk(i).model;
> ypred = svmPredict(model, X_val);
> size(find(ypred(find(ypred != Y_val))==1))(1) / size(ypred(find(ypred!=Y_val)))(1)
> endfor

ans =  0.85714
ans =  1
ans =  0.93750
ans =  1
ans =  0.93750
ans =  1
ans =  1
ans =  0.90909
ans =  0.92308
ans =  1
```

De lo que se extrae que el sistema clasifica muy bien el no spam como no spam, pero un poco peor al clasificar spam como no spam. Al cambiar los porcentajes de easy_ham, hard_ham y spam practicamente sólo se consigue empeorar el resultado, lo que puede indicar simplemente falta de ejemplos.

Probando para valores de C con sigma fijo a 1.14

Porcentaje Aciertos

C	**0.01000**	**0.10000**	**0.30000**	**1.00000**	**3.00000**	**8.0000**	**5.00000**	**10.00000**	**50.0000**
Avg	82.93939	83.15152	83.45455	85.72727	88.93939	89.0000	89.21212	89.30303	87.8788
Std	2.33893	2.32614	2.37980	2.47207	2.24989	2.1868	2.23041	2.26413	1.6424

Con lo que se muestra que C~8 es un buen valor

CONCLUSIONES

Los datos inicialmente no estaban bien distribuidos, ya que algunos eran más difíciles de clasificar que otros. Para arreglar esto, simplemente se mezclan.

Que no sean todos iguales de fáciles de clasificar implica que según la permutación que se coja puede dar un porcentaje de aciertos mayor o menor, por lo que para hacer que el porcentaje de aciertos varíe menos se toman más ejemplos de entrenamiento.

Cuando falla, suele hacerlo clasificando como spam un correo que no era. Cambiar el porcentaje de ejemplos easy_ham, hard_ham o spam usado no cambiaba este resultado, por lo que esto puede significar simplemente falta de ejemplos.